

CGV 무비챠트 크롤링 프로젝트

아키텍처 설계서

항목	내용
프로젝트명	CGV 무비챠트 크롤링 프로젝트
기본 문서	요구사항 정의서 v4.0
문서 버전	v1.2 (초안)
작성일	2026-09-07

CGV 무비차트 크롤링 프로젝트

아키텍처 설계서 | v1.2 (초안)

목차

1. 문서 개요.....	3
2. 설계 범위 및 요구사항 반영.....	3
3. 아키텍처 설계 원칙.....	3
4. 전체 플랫폼 아키텍처.....	4
5. 데이터 수집 아키텍처.....	4
6. 데이터 저장 아키텍처.....	5
7. 데이터 처리 아키텍처.....	5
8. 데이터 모델 및 스키마 설계.....	5
9. 데이터 흐름 및 인터페이스 설계.....	6
10. 보안 설계.....	6
11. 예외 처리 및 안정성 설계.....	6
12. 데이터 품질 및 검증 설계.....	7
13. 요구사항 추적성.....	7
14. 제약사항 및 TBD.....	7
부록 A. 권장 운영 흐름.....	8

1. 문서 개요

1.1 목적

본 문서는 CGV 무비챠트에서 영화 정보를 수집하고, 원천 데이터를 저장한 후 탐색적 데이터 분석(EDA)과 전처리를 수행하여 최종 데이터를 CSV 및 MySQL에 저장하는 데이터 파이프라인의 아키텍처를 정의한다.

1.2 설계 범위

- 동적 웹 페이지 기반 영화 정보 수집
- 포스터 이미지 로컬 저장
- 원천(Raw) 데이터 CSV 저장
- EDA 및 데이터 품질 확인
- 데이터 정제 및 표준화
- Clean CSV 생성
- MySQL 데이터 적재
- CSV 와 DB 결과 검증
- 보안, 예외 처리, 실행 이력 및 재현성 고려

1.3 설계 접근

요구사항을 수집, 저장, 처리, 적재, 검증의 데이터 라이프사이클로 재구성하고 각 기능을 독립적인 아키텍처 계층으로 설계한다.

2. 설계 범위 및 요구사항 반영

요구사항 영역	설계 반영
동적 크롤링	Selenium 기반 수집 계층
영화 정보 추출	파싱 및 데이터 수집 모듈
포스터 이미지 저장	이미지 다운로드 및 로컬 저장 모듈
항목별 예외 처리	오류 격리 및 계속 처리
Raw CSV	원천 데이터 저장 영역
EDA	데이터 품질 점검 영역
전처리	정제·정규화 처리 영역
Clean CSV	정제 데이터 저장 영역
MySQL	데이터 적재 및 조회 영역
결과 검증	건수·컬럼·적재 결과 검증
비기능 요구사항	안정성·보안·재현성 설계

3. 아키텍처 설계 원칙

- Raw 데이터와 Clean 데이터를 분리하여 원본 보존과 재처리를 지원한다.
- 수집, 처리, 저장, 검증 단계를 분리하여 변경 영향도를 최소화한다.
- 개별 영화 데이터의 오류가 전체 수집 작업을 중단시키지 않도록 항목 단위 예외 처리를 적용한다.
- DB 접속정보는 소스 코드와 분리하고 최소 권한 원칙을 적용한다.
- 입력·출력 건수와 실행 이력을 기록하여 처리 결과를 추적 가능하게 한다.

- 동일한 처리 로직을 기준으로 결과 재현성을 확보한다.

4. 전체 플랫폼 아키텍처

전체 데이터 흐름은 다음과 같다.

CGV 무비차트 → Selenium 수집(포스터 이미지 저장 포함) → Raw CSV → EDA/전처리 → Clean CSV → MySQL 적재 → 결과 검증

계층	주요 구성요소	역할
Source	CGV 무비차트	영화 정보 원천
Ingestion	Selenium WebDriver, Parser	동적 페이지 접근 및 데이터 추출
Raw Storage	cgv_movie_raw_{수집일자}.csv	수집 원본 보존
Media Storage	data/raw/posters/{수집일자}/*.jpg	포스터 이미지 원본 보존
Processing	Pandas, EDA, Cleaning	품질 점검·정제·정규화
Clean Storage	cgv_movie_clean_{수집일자}.csv	최종 정제 데이터 저장
Serving	MySQL movie_chart	구조화된 데이터 저장
Validation	검증 모듈	CSV/DB 결과 확인

5. 데이터 수집 아키텍처

5.1 수집 흐름

수집 모듈은 Selenium WebDriver를 이용하여 대상 페이지의 동적 렌더링 완료를 대기한 후 영화 목록을 탐색하고, 각 영화 항목의 정보와 포스터 이미지를 추출한다.

5.2 주요 처리

- 대상 페이지 접속
- 동적 콘텐츠 렌더링 대기
- 영화 목록 탐색
- 영화별 속성 추출
- 포스터 이미지 다운로드 및 로컬 저장
- 항목별 오류 기록
- 수집 결과 메모리 적재

5.3 예외 처리

개별 항목에서 파싱 오류가 발생한 경우 오류 정보를 기록하고 다음 항목의 처리를 계속한다. 페이지 렌더링 실패는 정의된 대기 및 추가 대기 정책에 따라 처리한다. 포스터 이미지 다운로드가 실패한 경우에도 해당 항목의 나머지 정보 수집과 다음 항목 처리에는 영향을 주지 않는다.

6. 데이터 저장 아키텍처

영역	저장소	목적	특성
Raw Zone	data/raw/cgv_movie_raw_{수집일자}.csv	원천 데이터 보존	수집 결과 추적 및 재처리 기준
Media Zone	data/raw/posters/{수집일자}/	포스터 이미지 원본 보존	항목 단위 파일, 저장 실패 허용

영역	저장소	목적	특성
Clean Zone	data/cgv_movie_clean_{수집일자}.csv	정제 데이터 저장	분석 및 DB 적재 기준
Serving Zone	MySQL movie_chart.cgv_movies	구조화된 최종 데이터	조회 및 후속 활용, 실행마다 재생성

Raw와 Clean 데이터를 분리하여 원본 손실 없이 전처리 로직을 변경하거나 재실행할 수 있도록 한다.

Raw/Clean CSV와 포스터 이미지는 파일명 또는 폴더명에 수집일자를 포함하여 회차별로 누적 보존되는 반면, MySQL Serving Zone은 실행마다 테이블을 재생성하는 방식으로 최신 회차만 유지한다. 이 정책 차이는 14장 제약사항 및 TBD에서 다룬다.

7. 데이터 처리 아키텍처

7.1 처리 단계

- EDA 수행
- 결측값 확인
- 중복 데이터 확인
- 문자열 정리
- 에그지수 표기 포매팅 ('%' 부여)
- 관람등급 정규화
- 개봉 구분 정규화
- 날짜 형식 표준화
- 최종 스키마 검증

7.2 처리 원칙

전처리 단계는 Raw 데이터를 직접 덮어쓰지 않고 별도의 Clean 데이터를 생성한다. 데이터 변환 전후의 건수 차이가 발생하는 경우 원인을 확인할 수 있도록 처리 결과를 기록한다.

8. 데이터 모델 및 스키마 설계

최종 정제 데이터는 요구사항 정의서에 제시된 다음 컬럼을 기준으로 관리한다.

컬럼	설명
rank	영화 순위
title	영화 제목
egg_index	에그 지수 (전처리 단계에서 '%' 표기 부여)
cumulative_viewers_count	누적 관객 수
is_re_release	재개봉 여부
release_date	개봉일
age_rating	관람 등급
poster_url	포스터 URL
crawled_at	크롤링 시각
source_url	수집 원본 URL

8.1 MySQL 테이블 설계 원칙

- 최종 Clean 데이터 스키마와 논리적으로 일관된 컬럼 구조 유지
- 적재 전 데이터 타입 및 NULL 값 검증
- 중복 적재 방지를 위한 운영 기준 정의
- 실제 물리 타입은 구현 환경과 수집 데이터 특성을 확인하여 확정

9. 데이터 흐름 및 인터페이스 설계

단계	입력	처리	출력
수집	CGV 웹 페이지	동적 렌더링·파싱, 이미지 다운로드	영화 데이터, 포스터 이미지 파일
Raw 저장	수집 데이터	파일 직렬화	Raw CSV
EDA	Raw CSV	결측·중복·분포 확인	품질 확인 결과
전처리	Raw 데이터	정제·정규화	Clean 데이터
Clean 저장	Clean 데이터	CSV 저장	Clean CSV
DB 적재	Clean CSV/DataFrame	스키마 검증·적재	MySQL 테이블
검증	CSV 및 DB	건수·컬럼 비교	검증 결과

10. 보안 설계

10.1 비밀번호 관리

- DB 접속정보는 환경변수 또는 .env 파일로 관리한다.
- 소스 코드에 비밀번호 및 접속정보를 하드코딩하지 않는다.
- .env 파일은 버전 관리 대상에서 제외한다.
- 배포 환경에서는 별도의 Secret 관리 방식을 적용할 수 있도록 구성한다.

10.2 접근 통제

- DB 관리자 계정과 애플리케이션 계정을 분리한다.
- 애플리케이션 계정에는 필요한 최소 권한만 부여한다.
- MySQL 의 외부 공개를 최소화하고 허용된 애플리케이션 환경에서만 접근하도록 제한한다.

10.3 데이터 적재 보안

- 외부에서 수집한 데이터를 신뢰하지 않고 스키마 및 데이터 타입을 검증한다.
- SQL 문자열 직접 조합을 지양하고 안전한 파라미터 처리 또는 적재 방식을 사용한다.
- 컬럼 길이, 날짜 형식, NULL 처리 기준을 검증한다.

10.4 로그 보안

- 비밀번호, 접속 문자열, 환경변수 값 등 민감정보를 로그에 기록하지 않는다.
- 오류 로그에는 필요한 식별 정보와 오류 원인만 기록한다.

11. 예외 처리 및 안정성 설계

상황	처리 정책
페이지 렌더링 지연	정의된 최대 대기 시간 적용
최초 렌더링 실패	추가 대기 후 재확인

상황	처리 정책
개별 영화 파싱 실패	오류 기록 후 다음 항목 처리
포스터 이미지 다운로드 실패	오류 기록 후 해당 항목 계속 처리, 전체 크롤링 중단하지 않음
데이터 형식 오류	전처리 단계에서 검증 및 처리
DB 연결 실패	오류 기록 및 적재 실패 상태 관리
DB 적재 오류	성공/실패 건수 기록 및 결과 검증

재시도 횟수, Backoff 정책 등 세부 운영값은 요구사항의 TBD 또는 구현 정책으로 별도 확정한다.

12. 데이터 품질 및 검증 설계

12.1 품질 검증 항목

- 수집 데이터 건수 확인
- 필수 컬럼 존재 여부 확인
- 결측값 확인
- 중복 데이터 확인
- 전처리 전후 건수 비교
- 포스터 이미지 저장 성공 여부 확인
- Clean CSV 와 MySQL 적재 결과 비교

12.2 실행 이력

항목	기록 내용
Run ID	실행 단위 식별자
Crawled Count	수집 건수
Raw Count	Raw 저장 건수
Clean Count	정제 완료 건수
Rejected Count	제외 또는 처리 실패 건수
Inserted Count	DB 적재 성공 건수
Failed Count	DB 적재 실패 건수

실행 이력은 데이터 누락, 변환 오류, 적재 오류를 추적하기 위한 운영 정보로 활용한다.

13. 요구사항 추적성

요구사항	설계 컴포넌트	검증 방법
FR-01~FR-02	수집/파싱 모듈	대상 데이터 수집 여부 확인
FR-03	예외 처리 모듈	개별 오류 발생 후 계속 처리 확인
FR-04	Raw Storage	Raw CSV 생성 확인
FR-05	EDA 모듈	품질 점검 결과 확인
FR-06	Processing 모듈	전처리 규칙 적용 확인
FR-07	Clean Storage	Clean CSV 및 스키마 확인
FR-08	DB Loader	MySQL 적재 확인
FR-09	Validation 모듈	CSV/DB 건수·컬럼 비교

요구사항	설계 컴포넌트	검증 방법
FR-10	이미지 저장 모듈	포스터 이미지 파일 생성 여부 확인

14. 제약사항 및 TBD

다음 항목은 요구사항 정의서의 진행 상황 및 추가 협의가 필요한 사항으로, 확정된 설계와 구분하여 관리한다.

- 노트북 또는 구현 산출물의 저장 형식 표기와 실제 CSV 구현 간 정합성 확인
- egg_index 및 cumulative_viewers_count 의 숫자형 변환 기준 확정
- 상세 페이지 URL 추가 수집 여부 확정
- 재시도 횟수 및 Backoff 정책 확정
- 개봉 완료 영화의 release_date 결측값 보강 정책 확정
- MySQL 물리 데이터 타입 및 키 제약조건 확정
- Raw/Clean 파일의 날짜별 누적 저장과 MySQL 테이블 재생성(덮어쓰기) 간 이력 관리 정책 통일 여부 확정
- 포스터 이미지 파일과 데이터 레코드를 연결할 컬럼(예: poster_image_path) 추가 여부 확정
- 포스터 이미지 다운로드 실패 시 재시도 정책 확정

부록 A. 권장 운영 흐름

1) 크롤링 실행(포스터 이미지 저장 포함) → 2) Raw CSV 저장 → 3) EDA 및 품질 확인 → 4) 전처리 → 5) Clean CSV 저장 → 6) 스키마 검증 → 7) MySQL 적재 → 8) 결과 비교 → 9) 실행 이력 기록