

REQUIREMENTS DEFINITION DOCUMENT

CGV 무비차트 크롤링 프로젝트 요구사항 정의서

항목	내용
프로젝트명	CGV 무비차트 크롤링 프로젝트
문서 버전	v4.0 (초안)
작성일	2026-09-07
작성자	강연재 (개인 프로젝트 · 크롤링/전처리/DB 적재 전체 담당)

CGV 무비챠트 크롤링 프로젝트

요구사항 정의서 | v4.0 (초안)

항목	내용
문서 버전	v4.0 (초안)
작성일	2026-09-07
대상 시스템	CGV 무비챠트(tabParam=144) 동적 크롤링 → 전처리 → MySQL 적재 파이프라인
문서 목적	노트북 최신본에서 달라진 수집·저장 로직(파일명 규칙, 포스터 이미지 저장 등)을 요구사항에 반영하고, 추가로 확인·결정이 필요한 사항을 정리한다.
작성자	강연재 (개인 프로젝트 · 크롤링/전처리/DB 적재 전체 담당)
검토자	자체 검토
문서 상태	초안 — 파이프라인 구현이 진행 중이며, 13장 TBD 항목은 결정 전 상태로 관리

개정 이력

버전	일자	주요 변경 내용
v1.0	-	초기 요구사항 정의
v2.0	-	구현 착수 전 요구사항 정의서로 재작성 (FR-01~09, 데이터/DB 스키마 확정)
v3.0	2026-08-26	cgv_crawling.ipynb 구현 내용과 대조하여 정합화. 인수 기준을 검증 방법 포함 표로 확장, 요구사항 추적성 매트릭스 신설, 확인 필요 항목(TBD) 절 신설. 관람 등급·개봉구분 정규화 규칙을 데이터 요구사항에 명문화.
v3.1	2026-08-27	문서 보강: 페이지 번호·목차(2장) 추가, 작성자/검토자/문서 상태 표 신설, 부록 A 용어 정의 신설.
v4.0	2026-09-07	노트북 최신본 반영: ① Raw/Clean CSV 파일명에 수집 일자(YYYYMMDD)를 포함하도록 변경, ② 포스터 이미지 로컬 저장 기능(FR-10) 추가, ③ egg_index 원본 값에는 '%' 기호가 없고 전처리 단계에서 부여됨을 반영해 데이터 요구사항 수정, ④ 파일(날짜별 누적)과 MySQL(매회 재생성) 간 이력 관리 정책 차이를 TBD로 추가.

목차

1. 프로젝트 개요.....	3
2. 목적.....	3
3. 프로젝트 범위.....	3
4. 요구사항 정의 원칙.....	3
5. 기능 요구사항.....	4
6. 비기능 요구사항.....	4
7. 데이터 요구사항.....	5
8. 저장 구조.....	6
9. 데이터베이스 스키마 (cgv_movies).....	6
10. 처리 흐름.....	7
11. 인수 기준.....	7
12. 요구사항 추적성 매트릭스.....	7
13. 확인·결정 필요 항목 (TBD).....	8
14. 산출물.....	9
부록 A. 용어 정의.....	9

1. 프로젝트 개요

CGV 무비차트 페이지(<https://cgv.co.kr/cnm/cgvChart/movieChart?tabParam=144>)의 공개 데이터를 Selenium으로 동적 수집하고, 수집한 원천 데이터를 Raw CSV로 중간 저장한 후 Pandas로 전처리하여 최종 CSV와 MySQL 데이터베이스에 저장하는 데이터 수집 파이프라인을 구축한다.

2. 목적

- CGV 무비차트 페이지는 JavaScript(Next.js) 기반으로 동적 렌더링되므로, Selenium 기반 동적 페이지 수집 방식을 크롤링 파이프라인에 적용한다.
- 크롤링 → 중간 저장 → 전처리 → 최종 저장 → DB 적재로 이어지는 데이터 파이프라인 전체 흐름을 구현한다.
- 원본 데이터와 정제 데이터를 분리 관리하여 데이터 품질을 검증할 수 있는 구조를 만든다.

3. 프로젝트 범위

3.1 포함 범위

- CGV 무비차트 목록 페이지 1 개(tabParam=144)에서 노출되는 차트 항목 수집
- Selenium 을 이용한 동적 크롤링
- 수집한 각 영화의 포스터 이미지를 항목 단위로 다운로드하여 로컬 파일로 저장
- 수집 원본 데이터의 Raw CSV 중간 저장
- Pandas 를 이용한 데이터 전처리 및 품질 검증(EDA)
- 전처리 결과의 최종 CSV 저장
- MySQL 데이터베이스 적재 및 저장 결과 검증

3.2 제외 범위

- 페이지네이션 등 CGV 무비차트 외 다른 목록/페이지 수집
- 스케줄링(정기 자동 수집), 알림 기능
- 영화 가격 정보 — 상세 페이지에서 실제 가격을 확인할 수 없어 수집 대상에서 제외
- 상세 URL(detail_url) 수집 — 노트북 FR 표에는 언급되었으나 실제 구현·본 요구사항서에는 포함되지 않음 (13 장 참고)
- 실행 회차별 이력 관리 — 파일은 날짜별로 누적되나, DB 이력 누적 여부는 미정 (13 장 TBD-06 참고)

4. 요구사항 정의 원칙

요구사항은 특정 라이브러리 호출이 아니라 파이프라인이 만족해야 할 결과와 품질을 중심으로 기술한다. 다만 본 프로젝트는 Selenium + Pandas + MySQL 스택이 학습 목적상 확정된 제약사항이므로, 구현 세부 함수명까지 요구사항에 준하는 수준으로 명시할 수 있다. 정량 기준이 아직 정해지지 않은 항목은 임의 수치로 채우지 않고 13장 TBD로 관리한다.

5. 기능 요구사항

전체 파이프라인은 다음 기능 요구사항을 만족해야 한다.

ID	요구사항	내용	우선순위
FR-01	동적 페이지 접근	Selenium으로 CGV 무비차트 페이지에 접속하고 목록 렌더링을 대기한다.	Must
FR-02	영화 목록 수집	순위, 영화명, 에그지수, 누적관객수, 개봉정보, 관람등급, 포스터 URL을 수집한다.	Must
FR-03	수집 실패 허용	항목 단위 수집 실패가 발생해도 전체 크롤링이 중단되지 않고 나머지 항목을 계속 수집한다.	Must
FR-04	중간 저장	크롤링 직후 원본 데이터를 Raw CSV(data/raw/cgv_movie_raw_{수집일자}.csv)로 저장한다. 파일명의 수집일자는 YYYYMMDD 형식이다.	Must
FR-05	데이터 점검(EDA)	전처리 전 원본 데이터의 행/열, 자료형, 결측치, 중복 여부를 확인한다.	Should
FR-06	데이터 전처리	문자열 정리, 관람등급/개봉구분 정규화, 날짜 표준화, 중복 제거를 수행한다.	Must
FR-07	최종 CSV 저장	전처리 결과를 UTF-8-SIG 인코딩 CSV(data/cgv_movie_clean_{수집일자}.csv)로 저장한다.	Must
FR-08	MySQL 저장	.env 접속정보를 이용해 movie_chart DB의 cgv_movies 테이블에 저장한다.	Must
FR-09	결과 검증	CSV 건수와 MySQL 저장 건수, 주요 컬럼을 비교하여 정상 저장 여부를 확인한다.	Should
FR-10	포스터 이미지 저장	수집한 각 영화의 포스터 이미지를 다운로드하여 data/raw/posters/{수집일자}/ 폴더에 '순위_영화명.jpg' 형식으로 저장한다. 개별 이미지 저장 실패가 전체 수집을 중단시키지 않는다.	Should

6. 비기능 요구사항

구분	내용
안정성	차트 요소 렌더링 지연 시 최대 20초 대기 후, 실패해도 3초 추가 대기로 복구를 시도한다.
예외 처리	항목 파싱 중 오류가 발생해도 해당 항목만 건너뛰고 로그를 남긴다.
이미지 다운로드	포스터 이미지 요청은 5초 타임아웃을 두며, 실패 시 해당 항목만 건너뛰고 크롤링을 계속한다.
인코딩	모든 CSV는 한글 깨짐 방지를 위해 UTF-8-SIG로 저장한다.
보안	DB 접속정보(.env)는 저장소에 포함하지 않고 로컬에서만 관리한다.
재현성	동일한 전처리 로직으로 여러 번 실행해도 동일한 결과가 나와야 한다.

7. 데이터 요구사항

7.1 수집 원본 데이터 (Raw) — data/raw/cgv_movie_raw_{수집일자}.csv

컬럼명	자료형	설명
rank	정수	차트 순위
title	문자열	영화명

컬럼명	자료형	설명
egg_index	문자열	에그지수 원본 값 (숫자 문자열, 예: "98") — '%' 기호는 포함하지 않는다.
cumulative_viewers_count	문자열	누적관객수 원본 값 (만/천 단위 포함, 예: "886.4만")
release_info_raw	문자열	개봉/재개봉 원본 텍스트
age_rating	문자열	관람등급 원본 값
poster_url	문자열	포스터 이미지 URL
crawled_at	문자열(datetime)	수집 시각
source_url	문자열	수집 대상 페이지 URL

포스터 이미지 파일은 data/raw/posters/{수집일자}/ 폴더에 별도로 저장되며, 위 Raw 데이터에는 이미지 파일 경로를 기록하는 컬럼이 없다 (13장 TBD-07 참고).

7.2 최종 정제 데이터 (Clean) — data/cgv_movie_clean_{수집일자}.csv

컬럼명	자료형	설명
rank	정수(Int64, nullable)	차트 순위
title	문자열	영화명 (공백 제거, 중복 제거 기준)
egg_index	문자열	에그지수 (예: "98%") — 원본 숫자 문자열 뒤에 '%' 를 붙여 표기한다. 수치 연산을 위한 변환은 아니다.
cumulative_viewers_count	문자열	누적관객수 (단위 포함 원문 유지, 예: "886.4만") — 숫자형 변환 없음
is_re_release	문자열(범주)	개봉 구분: 개봉 / 개봉예정 / 재개봉
release_date	문자열(YYYY-MM-DD) 또는 결측	개봉일. 이미 개봉된 영화는 원문에 날짜가 없어 결측으로 남는다.
age_rating	문자열(범주)	관람등급 (전체/12세/15세/18세/19세 관람가, 청소년 관람불가)
poster_url	문자열	포스터 이미지 절대 URL
crawled_at	문자열(datetime)	수집 시각
source_url	문자열	수집 대상 페이지 URL

7.3 정규화 규칙

관람등급(age_rating)은 다음 매핑 규칙에 따라 표준 값으로 정리한다: 전체관람가, 12세/15세/18세/19세 관람가, 청소년 관람불가(청불 포함). 매핑에 없는 원문은 공백만 제거한 원문 그대로 남긴다.

개봉 구분(is_re_release)은 release_info_raw 텍스트를 기준으로 다음과 같이 3분류한다: 원문에 "재개봉"이 포함되면 재개봉, "개봉"만 포함되면 개봉예정(향후 개봉 예정일이 명시된 경우), 원문 자체가 없으면 이미 개봉이 완료된 것으로 보아 개봉으로 분류한다.

에그지수(egg_index)는 원본에서 추출한 숫자만 있는 문자열(예: "98")에 '%' 문자를 덧붙여 표준 표기(예: "98%")로 저장한다. 원본 값이 비어 있거나 "-"인 경우 결측으로 처리한다.

8. 저장 구조

- 중간 저장: data/raw/cgv_movie_raw_{수집일자}.csv (수집일자는 YYYYMMDD 형식)
- 최종 파일 저장: data/cgv_movie_clean_{수집일자}.csv

- 포스터 이미지 저장: data/raw/posters/{수집일자}/{순위}_{영화명}.jpg
- DB 저장: MySQL movie_chart.cgv_movies (실행할 때마다 테이블을 재생성하여 이전 회차 데이터를 덮어쓰다 — 13 장 TBD-06 참고)
- DB 접속정보는 .env 의 DB_HOST, DB_PORT, DB_USER, DB_PASSWORD, DB_NAME 을 사용한다.

9. 데이터베이스 스키마 (cgv_movies)

컬럼명	타입	설명
id	INT (AUTO_INCREMENT, PK)	고유 식별자
rank	INT (NULL 허용)	차트 순위
title	VARCHAR(255) (NOT NULL)	영화명
egg_index	VARCHAR(10)	에그지수
cumulative_viewers_count	VARCHAR(20)	누적관객수
is_re_release	VARCHAR(20)	개봉 구분
release_date	DATE	개봉일
age_rating	VARCHAR(100)	관람등급
poster_url	TEXT	포스터 URL
crawled_at	DATETIME	수집 시각
source_url	TEXT	수집 대상 URL

MySQL 저장 단계는 매 실행 시 DROP TABLE IF EXISTS 후 테이블을 재생성하는 방식으로 구현되어 있어, 최신 실행 결과만 유지되고 이전 회차 이력은 남지 않는다.

10. 처리 흐름

사이트 선택 → 동적 크롤링(포스터 이미지 저장 포함) → 추출·수집 → Raw CSV 중간 저장 → EDA → 전처리 → 최종 CSV 저장 → MySQL DB 저장 → 결과 확인

11. 인수 기준

완료 기준을 인수 조건(AC)과 검증 방법으로 확장하여 정의한다. Must로 지정된 기능 요구사항은 원칙적으로 아래 조건을 모두 충족해야 인수 완료로 간주한다.

AC ID	인수 조건	검증 방법
AC-01	영화명이 없는 레코드는 최종 데이터에서 제외된다.	clean_df에서 title 결측 건수 = 0 확인
AC-02	영화명을 기준으로 중복 항목이 제거된다.	clean_df.duplicated(subset=['title']) = 0 확인
AC-03	순위는 숫자형(Int64)으로 변환된다.	clean_df['rank'].dtype 확인
AC-04	개봉일은 YYYY-MM-DD 형식으로 통일된다 (개봉 완료작은 결측 허용).	release_date 정규식 매칭 및 결측 사유 확인
AC-05	관람등급은 사전 정의된 표준 값으로 정리된다.	age_rating 값이 7.3 매핑 표 값 집합에 포함되는지 확인
AC-06	최종 CSV의 컬럼 순서와 개수(10개)가 정의	result_df.columns.tolist() == expected_columns assert

AC ID	인수 조건	검증 방법
	된 스키마와 일치한다.	
AC-07	CSV 저장 건수와 MySQL 저장 건수가 일치한다.	len(clean_df)와 SELECT COUNT(*) 비교
AC-08	항목 단위 수집 실패가 전체 크롤링을 중단시키지 않는다.	의도적 파싱 오류 주입 후 나머지 항목 수집 여부 확인
AC-09	DB 접속정보(.env)가 저장소(Git)에 포함되지 않는다.	.gitignore 및 저장소 파일 목록 점검
AC-10	포스터 이미지 다운로드 실패가 전체 크롤링을 중단시키지 않는다.	의도적으로 이미지 요청을 실패시킨 후 나머지 항목이 계속 수집되는지 확인

12. 요구사항 추적성 매트릭스

각 기능 요구사항이 노트북의 어느 단계에서 구현되고 무엇으로 검증되는지 연결한다.

요구사항 ID	구현 위치 (노트북 섹션)	검증 산출물
FR-01	"기본 설정" / "드라이버 생성 함수 정의" (build_driver, collect_chart_list)	차트 항목 수 로그 출력
FR-02	collect_chart_list 내 rank/title/egg_index/cumulative_viewers/age_rating 추출 로직	raw_df.head(10) 표시
FR-03	collect_chart_list의 for-try/except 루프	"N위 수집 실패" 로그, 부분 실패 시에도 결과 반환
FR-04	"중간 저장 (Raw CSV)" 셀 (RAW_CSV_PATH에 today_str 포함)	data/raw/cgv_movie_raw_{수집일자}.csv 파일 생성
FR-05	"데이터 이해 (EDA)" 셀	shape/dtypes/결측치/중복 출력
FR-06	"데이터 전처리" 셀 (preprocess_movie_data 및 하위 함수)	clean_df.head(10), 전처리 결과 검증 셀
FR-07	"최종 저장" 셀 (FINAL_CSV_PATH에 today_str 포함)	data/cgv_movie_clean_{수집일자}.csv 파일 생성
FR-08	"MySQL 데이터베이스 저장" 셀	"MySQL 저장 완료: N건" 로그
FR-09	"최종 결과 확인" 셀	CSV 건수 vs MySQL 건수 비교 출력
FR-10	collect_chart_list 내 포스터 다운로드 로직 (requests.get 및 파일 저장)	data/raw/posters/{수집일자}/폴더 내 이미지 파일 생성, 저장 실패 시 경고 로그 출력

13. 확인·결정 필요 항목 (TBD)

아래 항목은 노트북과 문서를 대조하는 과정에서 발견된 불일치 또는 미확정 사항이다. 개발자와 합의 후 해당 절을 갱신한다.

TBD ID	항목	현재 상태 / 결정이 필요한 이유
TBD-01	노트북 개요 셀의 저장 포맷 표기	"JSON으로 중간 저장"이라고 되어 있으나 실제 구현은 CSV. 노트북 마크다운 셀 텍스트 수정 필요.
TBD-02	egg_index /	현재 문자열 유지로 구현·DB 스키마 확정. 향후 분석 단계

TBD ID	항목	현재 상태 / 결정이 필요한 이유
	cumulative_viewers_count 숫자형 변환 여부	에서 숫자 연산이 필요하면 정규화 컬럼 추가 여부를 별도 결정.
TBD-03	노트북 내 FR-02 표의 "상세 URL" 문구	실제로는 수집하지 않는 항목이 노트북 자체 FR 표에 남아 있음. 표 문구 삭제 또는 상세 URL 수집 기능 추가 여부 결정 필요.
TBD-04	재시도(Backoff) 정책	현재 렌더링 대기(20초)+추가 대기(3초) 외에 별도 HTTP 재시도 로직 없음. 필요 시 재시도 횟수·간격 기준 결정.
TBD-05	release_date 결측 처리	이미 개봉된 영화는 원문에 날짜가 없어 release_date가 결측으로 남는다. 개봉일을 별도로 보강 수집할지 여부 결정 필요.
TBD-06	파일과 DB의 이력 관리 정책 불일치	Raw/Clean CSV와 포스터 이미지는 수집일자별로 누적 저장되지만, MySQL cgv_movies 테이블은 실행마다 재생성되어 최신 회차만 남는다. 두 저장소의 이력 관리 정책을 통일할지 결정 필요.
TBD-07	포스터 이미지 파일과 레코드 연결	다운로드한 포스터 이미지의 파일 경로가 Raw/Clean 데이터에 컬럼으로 기록되지 않는다. poster_image_path 등 연결 컬럼 추가 여부 결정 필요.
TBD-08	포스터 이미지 다운로드 재시도 정책	현재 요청 1회, 5초 타임아웃 후 실패 시 재시도 없이 건너뛴다. 재시도 필요 여부 및 횟수 결정 필요.

14. 산출물

산출물	경로/위치
수집·전처리 노트북	cgv_crawling.ipynb
원본 데이터	data/raw/cgv_movie_raw_{수집일자}.csv
포스터 이미지	data/raw/posters/{수집일자}/
최종 데이터	data/cgv_movie_clean_{수집일자}.csv
데이터베이스 테이블	MySQL movie_chart.cgv_movies

부록 A. 용어 정의

본 문서와 노트북(cgv_crawling.ipynb)에서 사용하는 프로젝트 고유 용어와 약어를 정리한다.

용어	설명
tabParam	CGV 무비챠트 페이지에서 조회할 차트 종류를 지정하는 URL 파라미터. 144는 본 프로젝트가 수집 대상으로 삼은 차트 탭을 가리킨다.
에그지수 (골든에그지수)	CGV가 실관람객 평가를 집계해 산출하는 자체 만족도 지수(%). Raw 단계에서는 숫자만 저장되고, 전처리 단계에서 '%'가 붙는다.
누적관객수	개봉일부터 수집 시점까지의 누적 관람객 수. 원문이 만/천 단위 한글 표기(예: "886.4만")를 포함하므로 cumulative_viewers_count 컬럼에 원문 그대로 저장한다.
is_re_release	개봉 구분을 담는 컬럼명. release_info_raw 원문을 정규화하여 개봉 / 개봉예정 / 재개봉 세 값 중 하나로 분류한다 (7.3 참고).
release_info_raw	크롤링 시 수집한 개봉·재개봉 관련 원문 텍스트. 전처리 전 원본 값이며, is_re_release와 release_date 산출의 입력으로 쓰인다.

용어	설명
수집일자 (today_str)	노트북 실행 시점의 날짜(YYYYMMDD)로, Raw/Clean CSV 파일명과 포스터 이미지 저장 폴더명에 공통으로 사용되는 접미사.
포스터 이미지 로컬 저장	크롤링 중 각 영화의 포스터 이미지를 별도로 다운로드하여 data/raw/posters/{수집일자}/ 폴더에 파일로 저장하는 기능. 실패해도 전체 수집에는 영향을 주지 않는다.
EDA (Exploratory Data Analysis)	전처리 이전에 원본 데이터의 행/열 구조, 자료형, 결측치, 중복 여부를 점검하는 탐색적 데이터 분석 단계 (FR-05).
Raw CSV / Clean CSV	Raw CSV는 크롤링 직후 가공되지 않은 원본 저장 파일 (data/raw/cgv_movie_raw_{수집일자}.csv), Clean CSV는 전처리를 마친 최종 저장 파일(data/cgv_movie_clean_{수집일자}.csv)이다.
FR / AC	FR은 기능 요구사항(Functional Requirement, 5장), AC는 인수 조건(Acceptance Criteria, 11장)의 약어이다.
TBD (To Be Determined)	현재 시점에 결정되지 않아 추후 확정이 필요한 항목. 13장에서 관리하며 임의 수치로 채우지 않는다.
UTF-8-SIG	BOM(Byte Order Mark)이 포함된 UTF-8 인코딩 방식. 엑셀 등에서 한글 CSV를 열 때 문자 깨짐을 방지하기 위해 사용한다.